The Skool – Jens Dossel

Lab i SQL1

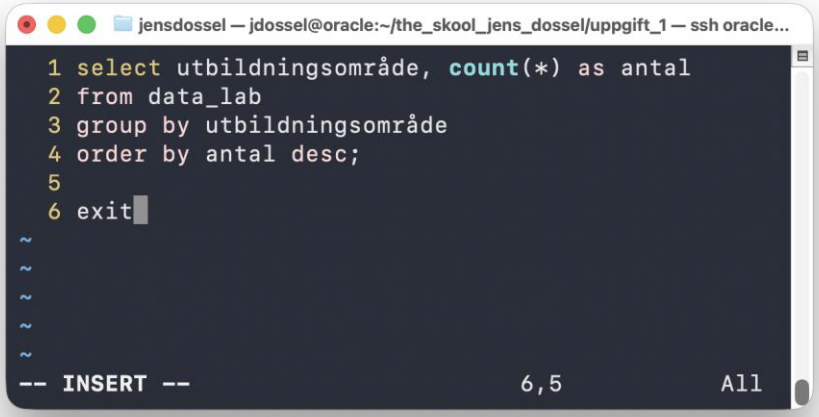
Uppgift 0 - uppvärmning

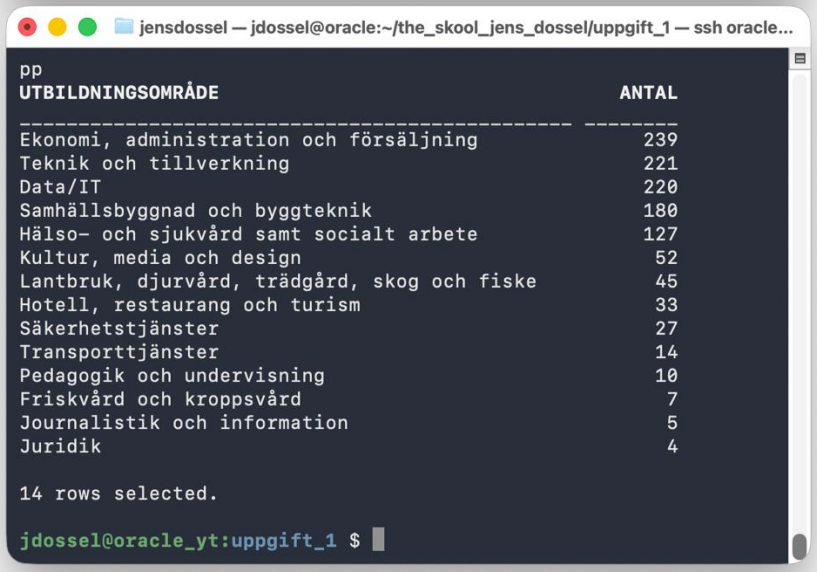
- Skapade repot i Github
- Klonade det tomma repot till vm: git clone
  git@github.com:dosselicious/the_skool_jens_dossel.git
  cd the_skool_jens_dossel
- Skapade .gitignore för att slippa swap-filer och macos metadata.
- Gjorde första commit.
- Laddade ner och rensade data-filen i excel, och skickade den sedan till repot: scp
  ~/Downloads/data_lab.xlsx oracle:/home/jdossel/the_skool_jens_dossel/
- Skapade databasen i orac:
  SQL> set loadformat xlsx
  SQL> load table data_lab data_lab.xlsx new
- Kontrollerade datan:
  SQL> desc data_lab
  select count(*) from data_lab;
  Jag fick med samtliga kolumner och 1184 rader.

Uppgift 1 – grundläggande EDA

a) Antal ansökningar per utbildningsområde, sorterat på flest ansökningar – uppgift_1/a_1.sql

Jag valde att se utbildningsområde och count(*) som antal från data_lab, och genom att gruppera på utbildningsområde får jag antal ansökningar, eller rader, per område. Sorterar på antal fallande. Scriptet avslutar orac med exit.



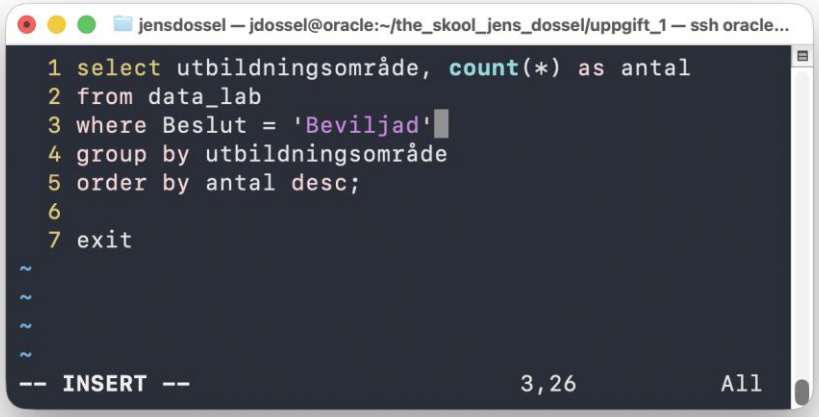


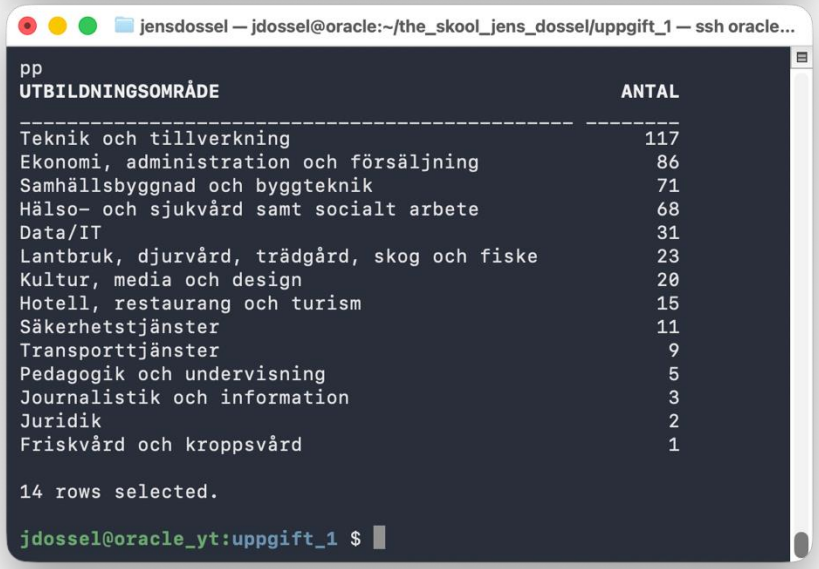
Uppgift 1 – grundläggande EDA

b) Antal BEVILJADE ansökningar per utbildningsområde– uppgift_1/b_1.sql

För att endast se de beviljade ansökningarna lade jag till villkoret att Beslut ska vara lika med ”Beviljad”.

where Beslut = 'Beviljad'



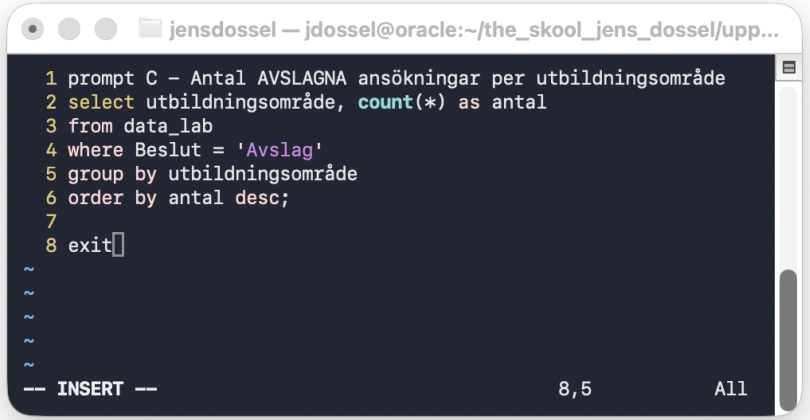


Uppgift 1 – grundläggande EDA

c) Antal AVSLAGNA ansökningar per utbildningsområde– uppgift_1/c_1.sql

För att endast se de avslagna ansökningarna ändrade jag villkoret till att Beslut ska vara lika med ”Avslag”.

where Beslut = ‘Avslag'





Uppgift 1 – grundläggande EDA

d) Antal BEVILJADE ansökningar per utbildningsnamn inom Data/IT – uppgift_1/d_1.sql

jensdossel — jdossel@oracle:~/the_skool_jens_dossel/upp...

```
 1 prompt D - Antal BEVILJADE ansökningar per utbildningsnamn ino
   m Data/IT
 2 select utbildningsnamn, count(*) as antal
 3 from data_lab
 4 where Beslut = 'Beviljad'
 5 and utbildningsområde = 'Data/IT'
 6 group by utbildningsnamn
 7 order by antal desc;
 8
 9 exit
~
~
~
"d_1.sql" 9L, 247B                              6,1           All
```

jensdossel — jdossel@oracle:~/the_skool_jens_dossel/upp...

```
ppD - Antal BEVILJADE ansökningar per utbildningsnamn inom Data/IT

UTBILDNINGSNAMN                                    ANTAL
-------------------------------------------------- --------
Technical Operations Specialist                           2
UX-designer                                               1
Game Programmer Specialization                            1
Spelutvecklare                                            1
.NET-utvecklare                                           1
AI-utvecklare med fokus på maskininlärning                1
Javautvecklare                                            1
Mjukvaruutvecklare, inbyggda system och IoT               1
Database Administrator - DBA                              1
Systemutvecklare DevSecOps                                1
Mjukvarutestare                                           1
Mjukvarutestare med testautomation                        1
QA Engineer                                               1
Data & Analytics Specialist                               1
Data Management                                           1
Data Scientist                                            1
Cyber Security Engineer                                   1
Identity and Access Manager IAM                           1
IT- och cybersäkerhetsspecialist                          1
IT-säkerhetsanalytiker                                    1

UTBILDNINGSNAMN                                    ANTAL
-------------------------------------------------- --------
IT-säkerhetsspecialist                                    1
IT-Säkerhetsspecialist                                    1
IT-Säkerhetstestare                                       1
Cloud and IT-infrastructure specialist                    1
IT-infrastructure secure cloud                            1
IT-infrastrukturtekniker - Moln & Säkerhet                1
IT-infrastrukturtekniker - moln & säkerhet                1
UX Designer                                               1
Game Developer                                            1
Game Programmer                                           1

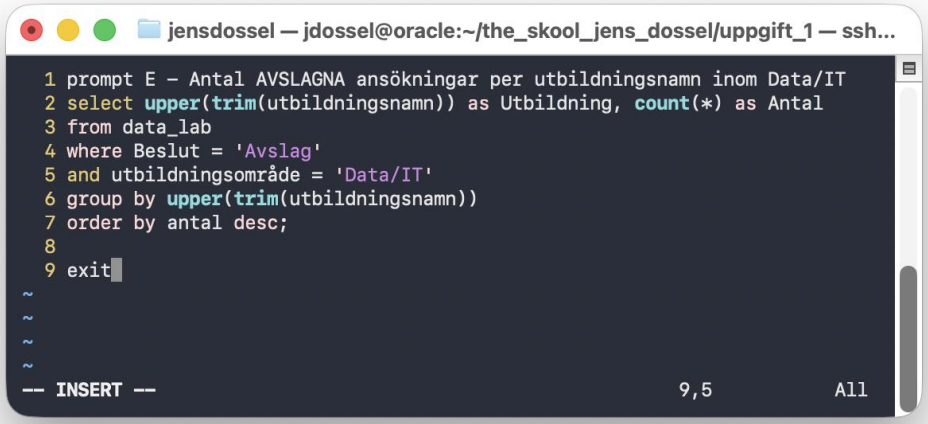
30 rows selected.
```

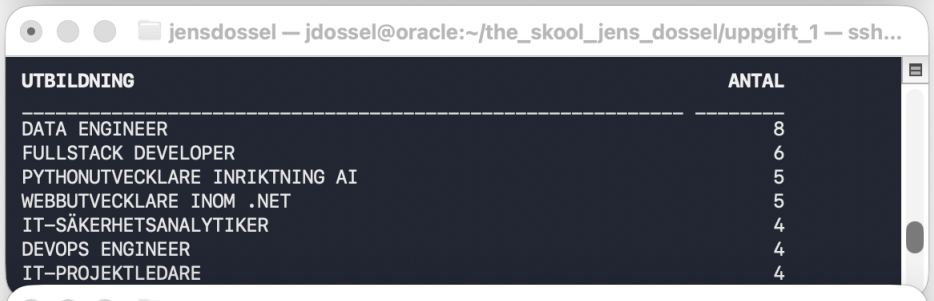
Här väljer jag select utbildningsnamn, count(*), lägga till villkoren where Beslut = ’Beviljad’ and utbildningsområde = ’DATA/IT’ samt gruppera på utbildningsnamn.

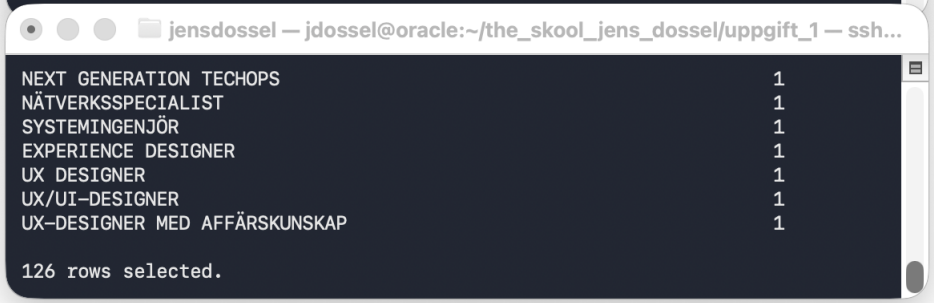
Uppgift 1 – grundläggande EDA

e) Antal AVSLAGNA ansökningar per utbildningsnamn inom Data/IT – uppgift_1/e_1.sql

Här började jag med att bara ersätta villkoret från förra frågan från ’Beviljad’ till ’Avslag’, men upptäckte att jag fick flera dubbletter beroende på case (Data Engineer och Data engineer) och blanksteg i slutet av utbildningens namn (.Net Developer och .Net Developer_), så jag lade till upper för att göra alla bokstäver till versaler och trim för att ta bort eventuella blanksteg före eller efter namnet.
Antal rader i resultatet sjönk då från 135 till 126.





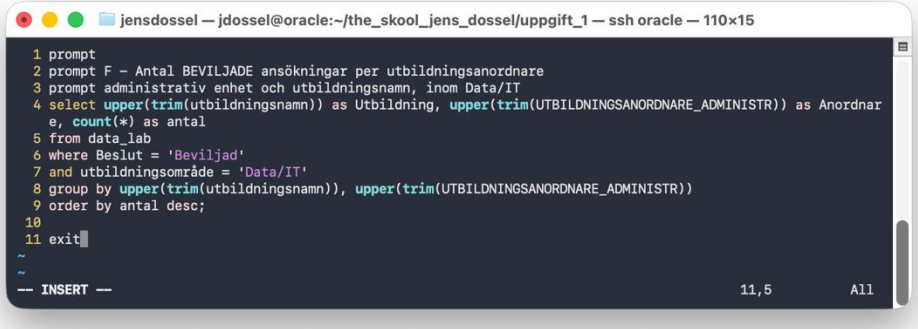


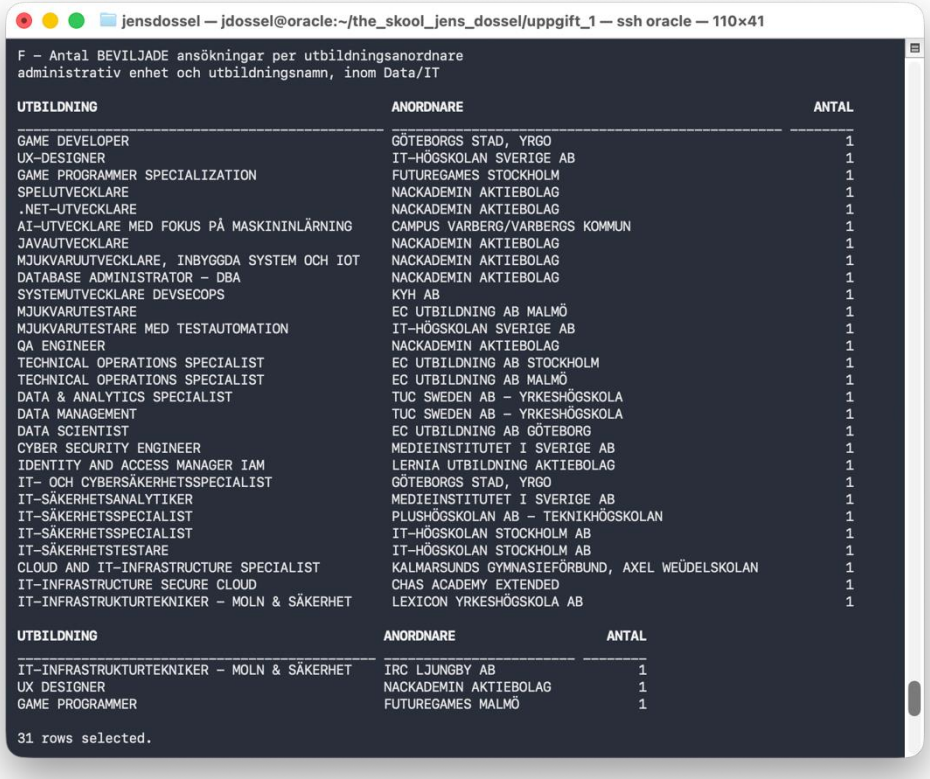
Uppgift 1 – grundläggande EDA

f) Antal BEVILJADE ansökningar per utbildningsandordnare administrativ enhet och utbildningsnamn inom Data/IT

– uppgift_1/f_1.sql

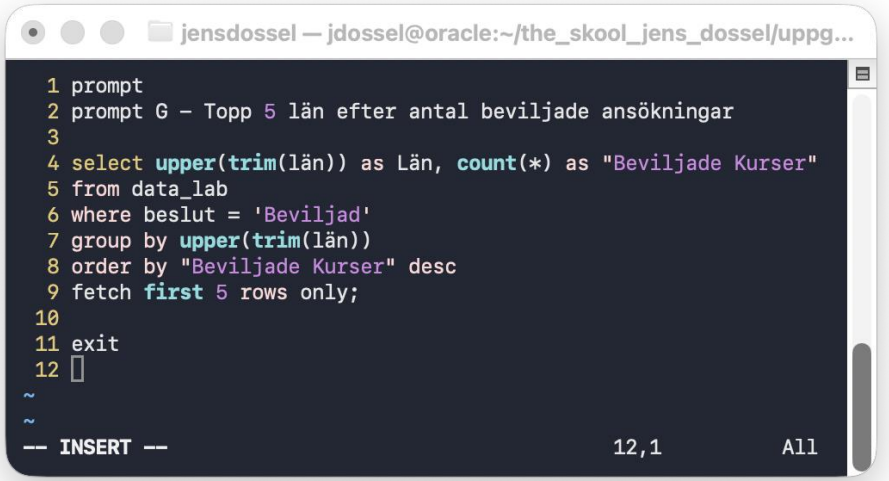
Jag utgick från fråga 1d och lade till utbildningsanordnarens administrativa enhet i SELECT och GROUP BY. Därmed grupperas resultatet efter unika kombinationer av utbildningsnamn och anordnare. Jag använder UPPER(TRIM()) för att hantera skillnader i stora och små bokstäver samt överflödiga blanksteg.





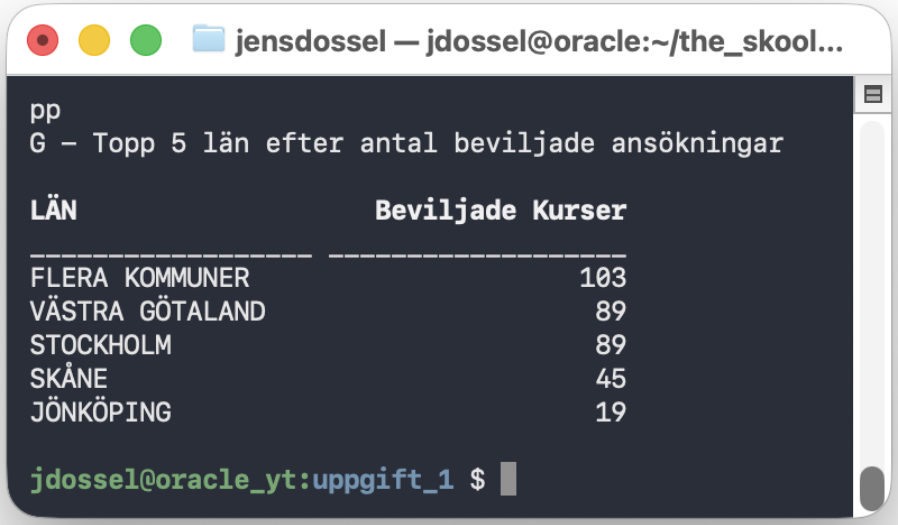
Uppgift 1 – grundläggande EDA

g) Topp 5 län efter antal beviljade ansökningar – uppgift_1/g_1.sql



En av skillnaderna i denna uppgift mot tidigare är att sortera efter våra räknade rader och därför får vår count(*) ett kolumnalias, ”Beviljade kurser”. En annan är att vi bara vill se topp 5, därav fetch first 5 rows only.

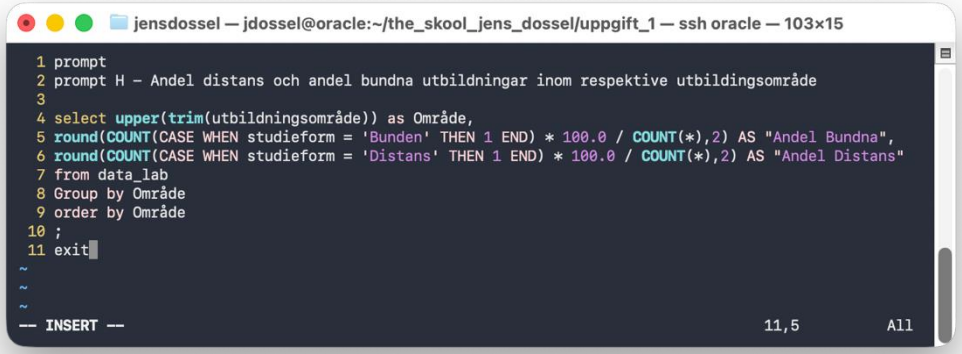
Bonus: Vill vi inte få med ”Flera kommuner” i resultatet, utan endast få faktiska län, kan vi lägga till AND UPPER(TRIM(län)) <> 'FLERA KOMMUNER’ till vårt WHERE-villkor.



Uppgift 1 – grundläggande EDA

h) Andel distans och andel bundna utbildningar inom respektive utbildingsområde

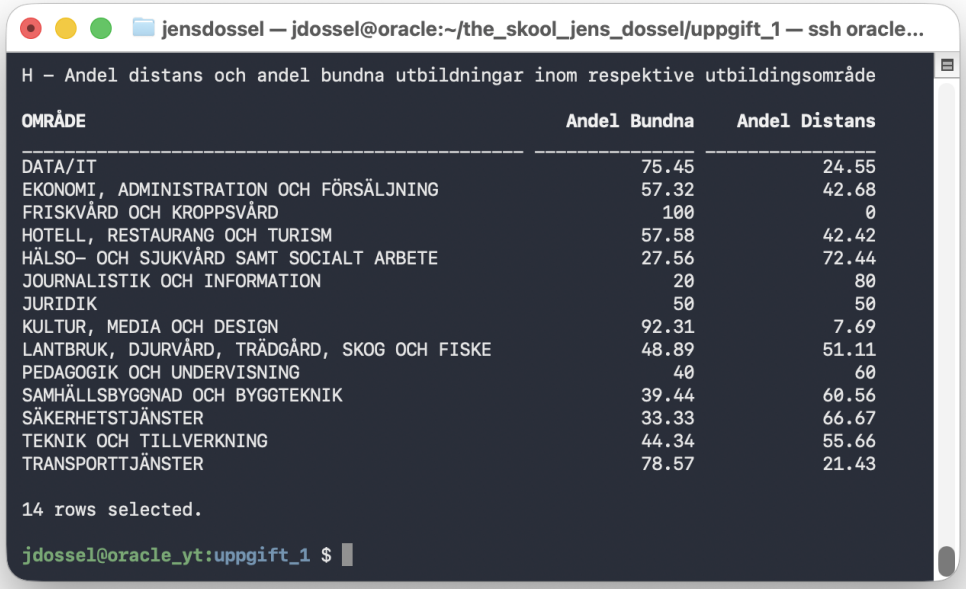
– uppgift_1/h_1.sql



I denna fråga använder vi aggregeringsfunktionen COUNT och villkorsuttycket CASE.

round(**COUNT**(CASE WHEN studieform = 'Bunden' THEN 1 END) * 100.0 / **COUNT**(*),2) AS "Andel Bundna”.

På ren svenska:
För varje rad där studieformen är ”Bunden” returnerar CASE värdet 1, annars NULL. COUNT räknar sedan alla värden som inte är NULL. Antalet multipliceras med 100 och delas med det totala antalet rader inom utbildningsområdet. Slutligen avrundas resultatet till två decimaler.



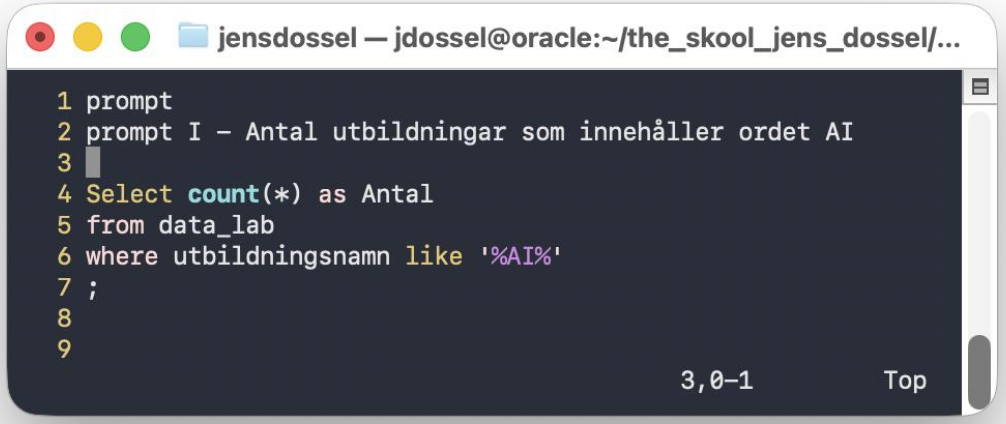
Uppgift 1 – grundläggande EDA

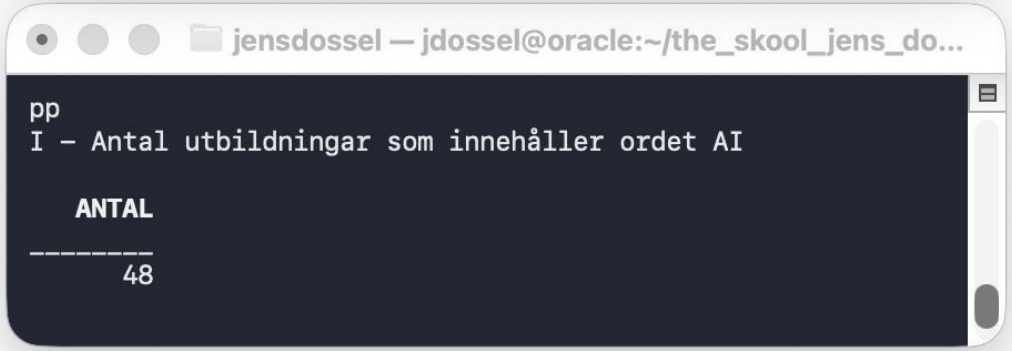
i) Antal utbildningar som innehåller ordet AI

– uppgift_1/i_1.sql

Här räknar vi antal rader där utbildningsnamn innehåller ”AI” genom att använda WHERE utbildningsnamn LIKE '%AI%’ som villkor.

LIKE används för mönstermatchning.
Jokertecknen % gör att vi hittar “AI” oavsett var i utbildningsnamnet teckensekvensen förekommer.





Uppgift 2 – Intervjua Domänexpert

Efter intervju med stakeholder är det etablerat att målet med datadriven analys är att hitta information om vilka utbildningar som har störst chans att bli beviljade, och varför. Utslagskriterier kan vara av geografisk, områdesmässig, omfattningsmässig och inriktningsmässig natur.

The Skool har inga begränsningar inom ovan nämnda områden.

Uppgift 3 – Datadrivna beslut

Jag vill börja med att undersöka vilka utbildningar som har högst beviljandegrad och hur många ansökningar resultaten bygger på.

Därefter vill jag undersöka om de mest framgångsrika utbildningarna har några gemensamma nämnare, exempelvis utbildningsområde, SUN5-inriktning studieform eller antal omgångar.

Slutligen vill jag identifiera utbildningar med hög beviljandegrad och undersöka i vilka län de inte har sökts under 2025, för att hitta möjliga etableringsmöjligheter för The Skool.

Uppgift 3 – Datadrivna beslut – Fråga A

Fråga A.1–A.4:
Vilka utbildningar har högst beviljandegrad, hur många ansökningar ligger bakom och vilken betydelse har studieformen?

Syfte:
Identifiera framgångsrika utbildningar och möjliga etableringsmöjligheter för The Skool genom att jämföra beviljandegrad, antal ansökningar och studieform.

Resultat:
268 utbildningsnamn hade minst 80 % beviljandegrad. Vid separata analyser uppfyllde 172 kriteriet som bundna och 124 som distansutbildningar.

Tandsköterska utmärkte sig med 17 av 17 beviljade ansökningar, fördelade på båda studieformerna.

Totalt beviljades 42,54 % av de bundna utbildningarnas ansökningar, jämfört med 35,02 % för distans – en skillnad på 7,52 procentenheter.

Slutsats:
Bundna utbildningar hade generellt högre beviljandegrad under 2025. Studieformen kan därför vara relevant för The Skools etableringsbeslut, men skillnaden kan även bero på utbildningsområde.

Utbildningar med hög beviljandegrad och flera ansökningar är särskilt intressanta att undersöka vidare.

Uppgift 3 – Datadrivna beslut – Fråga B

Fråga B.1–B.3:
Vilka SUN5-inriktningar har högst beviljandegrad, hur många ansökningar ligger bakom och vilken betydelse har studieformen?

Syfte:
Identifiera framgångsrika utbildningsinriktningar och undersöka om bunden utbildning eller distansutbildning ger olika resultat.

Resultat:
46 SUN5-inriktningar hade minst 80 % beviljandegrad totalt. När studieformerna analyserades separat uppfyllde 47 bundna och 32 distansinriktningar samma kriterium.

Skillnaden beror på att beviljandegraden beräknas separat för varje urval.

Exempelvis hade elkonstruktörsutbildningar 100 % beviljandegrad i bunden form (3 av 3), men endast 42,86 % på distans (3 av 7). Den sammanlagda beviljandegraden blev därför 60 %.

Tandsköterskeutbildningar utmärkte sig med 100 % beviljandegrad (17 av 17), fördelat på båda studieformerna.

Slutsats:
En inriktning kan vara framgångsrik inom en studieform utan att nå samma resultat totalt. The Skool bör därför väga in både studieform, beviljandegrad och antal ansökningar vid val av framtida utbildningar.

Uppgift 3 – Datadrivna beslut – Fråga C

Fråga C.1–C.3:
Vilka utbildningsområden har högst beviljandegrad, hur många ansökningar ligger bakom och vilken betydelse har studieformen?

Syfte:
Identifiera framgångsrika utbildningsområden och undersöka om bunden utbildning eller distansutbildning ger olika resultat.

Resultat:
Eftersom områden täcker ett större spann än tidigare frågor, så slopades här 80%-kravet. Resultatet är spretigt. Transporttjänster vann beviljandegraden med 64.29% av 14 ansökningar, medan DATA/IT kom på sista plats med 14.09% av 220 ansökningar. Stor skillnad sedan på bundet eller distans.

Slutsats:
Ämnet utbildningsområden är för stort och spretigt att analysera med dessa frågor. Här bör i en större analys varje område analyseras för sig. Med gällande världsutveckling inom DATA/IT exempelvis är det rimligt att undersöka om AI-relaterade utbildningar är mer attraktiva än programmering.

Uppgift 3 – Datadrivna beslut – Fråga D

Fråga D.1–D.4:
Vilka län och kommuner har högst beviljandegrad respektive högst antal beviljade kurser och platser, samt fördelning på bunden och distans

Syfte:
Identifiera geografiska skillnader och undersöka om bunden utbildning eller distansutbildning ger olika resultat.

Resultat:
Resultatet visar på skillnader i utfall geografiskt, och visar att även om ett område får en förhållandevis låg beviljandegrad, så kan det beviljas många utbildningar och platser.

Slutsats:
Frågan måste kombineras med andra i fråga om område och SUN5 för kunna analyseras vidare. En fråga att ta ställning till är om ort verkligen är intressant vid beviljande av distansutbildningar och det som bör utredas närmare är ifall vissa orter prioriteras av MYH på grund av arbetslöshet eller behov av specialistkompetens, exempelvis på grund av lokal brist på sjukvårdspersonal.

Uppgift 3 – Datadrivna beslut – Fråga E

Fråga E.1–E.4:
Hur ser beviljandegraden ut baserat på antal YH-poäng och sökta omgångar?

Syfte:
Undersöka om det finns samband mellan utbildningens längd, antalet sökta utbildningsomgångar och beviljandegraden, samt hur många omgångar som faktiskt beviljas.

Resultat:
Resultatet visar stora skillnader. Ca 90% av alla beviljade utbildningar har 3 omgångar, och 108 utbildningar som sökt 5 omgångar har blivit beviljade 3.
I fråga om YH-poäng har endast intervallet 300-399 fått fler än hälften av ansökningarna beviljade. Det största segmentet i mängd är 400-499 där 267 av 746 beviljades, eller 35,79%

Slutsats:
Resultaten visar att MYH i detta material oftast beviljar tre utbildningsomgångar, även när fler har sökts. Utbildningar på 300–399 YH-poäng har högst beviljandegrad, men det går inte att fastställa om utbildningens längd i sig påverkar beslutet.

Uppgift 3 – Datadrivna beslut – Fråga F

Nu har The Skool fått svar på hur beviljandegraden sett ut fördelat på en mängd olika faktorer, och egentligen är det upp till dem att analysera affärsmöjligheterna nu.

Men vi ska hjälpa dem med en sista fråga.
Vi vet redan vilka SUN5-inriktningar som hade 100% beviljandegrad, att inga områden fick 100%, att 3 utbildningsomgångar är det MYH verkar föredra och att 300 YH-poäng och högre verkar vara mest attraktiva, men:

Vilka bundna utbildningar har 100 % beviljandegrad, och i vilka län saknas ansökningar om dessa utbildningar?

Eftersom behovet av dessa kompetenser bedömdes vara högt, så kanska det alltså finnas ett fortsatt behov i de län där de aldrig ansöktes.

Först skapar vi två datasets med CTE för att ta reda på vilka utbildningar som haft 100% beviljandegrad och minst 3 ansökningar, och vilka olika län som finns, och sedan en cross join för att kunna kombinera dataseten och sist skapar vi frågan vilka av utbildningarna från första datasetet har INTE med något av de unika länen från det andra setet.

Uppgift 3 – Datadrivna beslut – Fråga F forts

Jag vill här understryka att min roll inte är affärsutvecklare åt The Skool. Om jag hade varit det, så hade jag velat ha flera års data att jämföra för att se eventuella trender etc.

Men mitt råd, baserat på resultaten, hade varit att satsa på utbildningar till tandsköterska i de län de INTE förekom i 2025 års lista, och i övrigt undersöka utbildningar på 300–400 YH-poäng och planera utifrån att tre utbildningsomgångar oftast beviljas.

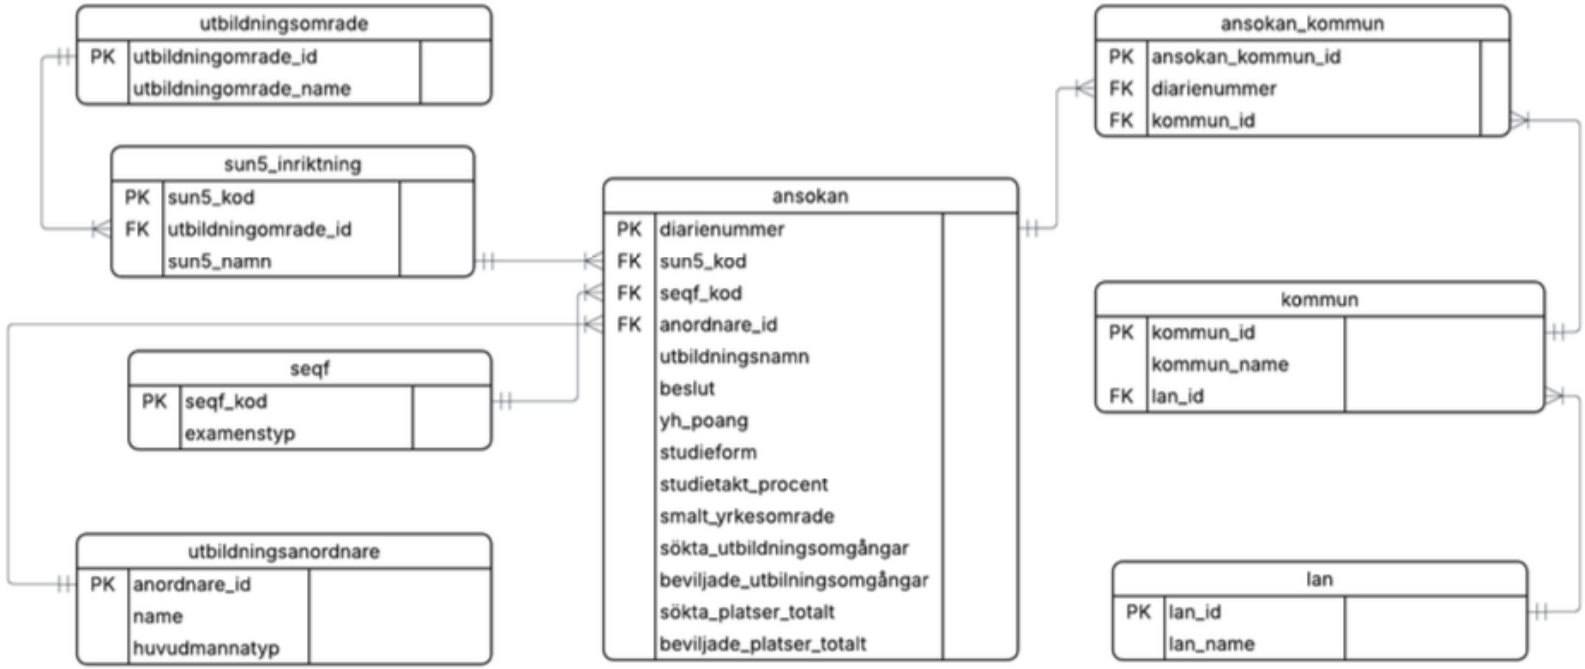
Så nästa steg är troligen att boka in möten med företrädare för tandvården i de länen för att sondera behovet närmare, samt om möjligt kontrollera varifrån studenterna på de 6 distans-utbildningarna till tandsköterska kom från för att eventuellt prioritera ned län med många studenter där.

The Skool bör även närmare kontrollera vilka kommuner som förekommer i ”Flera kommuner”. Jag uppfattade det inte som mitt uppdrag och har därför behandlat benämningen som ett län-namn.

Jag har, med hänsyn till projektets storlek, aktivt valt att inte undersöka ALLA kolumners relation till beviljandegrad. Hade det varit ett ”riktigt” projekt hade jag även undersökt exempelvis studietakt i kombination med YH-poäng etc. Jag har av samma orsak inte lagt ner tid på att städa upp data, även om jag sett behovet av det.

Uppgift 4 - Implementera datamodell (BONUS)

En konsult har varit vänlig nog att föreslå en datamodell av data_lab, antagligen för att bättre uppfylla kraven för första, andra och tredje normalformen (1NF–3NF).



Uppgift 4 - Implementera datamodell (BONUS)

Eftersom tabellen ansökningar är central, så började jag med att kolla om alla diarenummer verkligen är unika och därmed kan användas som primary key:

```
SELECT
COUNT(*) AS antal_rader,
COUNT(DISTINCT diarienummer) AS unika_diarienummer,
COUNT(*) - COUNT(diarienummer) AS null_varden
FROM data_lab;
```

ANTAL_RADER	UNIKA_DIARIENUMMER	NULL_VARDEN
1184	1184	0

Uppgift 4 - Implementera datamodell (BONUS)

Jag använde här de färdigheter vi lärde oss i Databasteori och i början av denna kurs för att skapa create_4.sql och insert_4.sql.

Precis som i Databasteorins library lab, var jag tvungen att tänka till kring vilken ordning insertsen skulle göras eftersom främmande nycklar måste finnas innan vi skapar tabeller som använder dem.

Sedan återanvände jag mina frågor från Uppgift 1 och återskapade dem med en JOIN-kedja baserad på:

```
FROM ansokan a
JOIN sun5_inriktning s ON a.sun5_kod = s.sun5_kod
JOIN utbildningsomrade o ON s.utbildningsomrade_id = o.utbildningsomrade_id
JOIN seqf q ON q.seqf_kod = a.seqf_kod
JOIN utbildningsanordnare u ON u.anordnare_id = a.anordnare_id
JOIN ansokan_kommun ak ON ak.diarienummer = a.diarienummer
JOIN kommun k ON k.kommun_id = ak.kommun_id
JOIN lan l ON l.lan_id = k.lan_id
```

Queryn finns i repot, uppgift_4/uppgift_1_revisited.sql.
Resultat jämfört med uppgift 1. Datan överenstämmer.
Observera att konsulten utelämnade vissa kolumner i sin skiss och att dessa därmed inte återskapats.